INTELIGENCIA ARTIFICIAL

PROYECTO FINAL

Antonio Miguel Corraliza Cervilla

New Technology School

Tokio.

New
Technology
School



Antonio Miguel Corraliza Cervilla

RESPONSABLE DEL DESARROLLO DE LA APLICACIÓN

Fecha: 02, 11, 2026

INTELIGENCIA ARTIFICIAL
PROYECTO FINAL
Antonio Corraliza

Tokio.

Indice:

1. Obtención y selección de datos.
2. Definición del problema y sus objetivos.
3. Limpieza de los datos.
4. Exploración de datos y observaciones.
5. Selección de modelo y justificación.
6. Representación final de los resultados con la librería SHAP.

1- Obtención y selección de datos:

Antes de nada quería explicar en este primer punto la forma de buscar y seleccionar el dataset en mi caso tuve en cuenta asta cinco datasets diferentes tres de los cuales tenían el target muy desbalanceado los otros dos los tenían mucho mas balanceado de esos dos finalmente escogí el dataset sobre la concesión de créditos hipotecarios un datasets con mas juego que el otro aquí dejo el enlace de la plataforma kaggle https://www.kaggle.com/datasets/architsharma01/loan-approval-prediction-dataset

Este dasets consta de 4269 filas y 13 columnas y no tiene valores nulos.

Se trata de un conjunto de datos tabular orientado al sector financiero y de banca, diseñado para la evaluación y predicción de riesgo de crédito en solicitantes de préstamos.

El dataset recopila múltiples dimensiones del perfil del cliente, abarcando variables socioeconómicas, datos laborales y métricas clave de solvencia financiera (como historiales de crédito, volúmenes de capital solicitados, importe y plazo del préstamo).

Aquí dejo un pequeño resumen del dataframe:

```
<class 'pandas.DataFrame'>
RangeIndex: 4269 entries, 0 to 4268
Data columns (total 13 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   loan_id                   4269 non-null   int64
 1    no_of_dependents         4269 non-null   int64
 2    education                4269 non-null   str
 3    self_employed            4269 non-null   str
 4    income_annum             4269 non-null   int64
 5    loan_amount              4269 non-null   int64
 6    loan_term                4269 non-null   int64
 7    cibil_score              4269 non-null   int64
 8    residential_assets_value 4269 non-null   int64
 9    commercial_assets_value  4269 non-null   int64
 10   luxury_assets_value      4269 non-null   int64
 11   bank_asset_value         4269 non-null   int64
 12   loan_status              4269 non-null   str
dtypes: int64(10), str(3)
memory usage: 433.7 KB
```

2- Definición del problema y sus objetivos.

Una vez obtenidos los datos vamos a definir el problema y sus objetivos.

Definición del Problema:

En el día a día de un banco o una entidad financiera, uno de los retos más importantes es decidir de forma rápida y justa a qué personas se les puede conceder un préstamo y a cuáles no. El problema principal consiste en adivinar, antes de prestar el dinero, si un cliente va a ser capaz de devolverlo o si, por el contrario, corre el riesgo de no pagar (lo que en banca se conoce como caer en mora o impago).

Tradicionalmente, esta tarea se ha hecho de forma muy manual o utilizando normas fijas y reglas matemáticas muy simples. Sin embargo, estas formas antiguas se quedan cortas hoy en día, ya que no consiguen ver las relaciones complejas que hay entre los datos de una persona: por ejemplo, cómo se combinan sus ingresos, el tiempo que pide el préstamo, los bienes que tiene y su historial de pagos anterior.

Por esta razón, plantear este reto como un problema automatizado permite analizar una gran cantidad de solicitudes con mayor objetividad, reduciendo el riesgo económico para la entidad y ayudando a tomar decisiones mucho más justas y eficientes.

Objetivo general:

Crear y comprobar un modelo de machine learnig que ayude a decidir de forma automática si se debe aprobar o denegar un préstamo a un solicitante, logrando que las predicciones sean fiables, seguras y, sobre todo, fáciles de explicar y entender.

Objetivos Específicos:

1. **Preparar y limpiar la información:** Buscar los datos más adecuados sobre los clientes, depurando errores y preparando la información para que el ordenador pueda trabajar con ella de forma limpia y ordenada.
2. **Enseñar al sistema a predecir:** Entrenar un modelo informático inteligente para que aprenda a distinguir con acierto qué perfiles tienen riesgo de no pagar y cuáles son solventes.
3. **Comprender el "porqué" de las decisiones:** Utilizar herramientas visuales para descubrir qué factores mira más el sistema (como el historial de crédito) a la hora de dar o rechazar un préstamo, asegurando que actúa con lógica.
4. **Presentar un trabajo útil y ordenado:** Exponer todo el desarrollo de forma clara en este documento académico, demostrando su posible aplicación práctica en el mundo de la banca y las finanzas.

3- Limpieza de datos.

Antes de enseñar a trabajar al sistema informático, es imprescindible poner a punto la información recopilada. Si usamos datos con errores o mal organizados, el modelo aprenderá mal y tomará malas decisiones. Para evitarlo, se realizaron tres tareas principales:

1. **Eliminación de errores y duplicados:** Se revisó que no hubiera datos incompletos o repetidos para no confundir al sistema con información falsa o contradictoria.
2. **Igualación de escalas (StandardScaler):** Se adaptaron todos los números a un mismo rango para que el sistema no dé más importancia a una variable solo porque su número sea más grande (por ejemplo, comparar miles de euros con meses de plazo).

3. **Revisión del equilibrio de los casos:** Se comprobó que el sistema tuviera suficientes ejemplos tanto de personas pagadoras como de impagos. Así se evita que el modelo cree una "trampa" y apruebe todos los préstamos automáticamente solo por ir a lo seguro.

4- Exploración de datos y observaciones.

Antes de pasar a entrenar el sistema, realizamos una exploración visual y estadística de la información para entender cómo se comportan las variables y qué relación tienen entre ellas. Las observaciones principales fueron las siguientes:

1. **El peso clave del historial crediticio (cibil_score):** El análisis confirmó que la puntuación de crédito del solicitante es el factor más determinante para saber si un préstamo va a ser aprobado o si existe riesgo de impago, alineándose perfectamente con la lógica de cualquier entidad bancaria.
2. **Relación lógica entre plazos y cantidades:** Se comprobó que los importes más elevados de dinero suelen ir asociados a plazos de devolución más largos, y que el comportamiento de pago varía de forma coherente según la estabilidad laboral y los activos declarados por los clientes.
3. **Detección de patrones claros:** Esta exploración previa demostró que los datos no son aleatorios; existen tendencias muy marcadas que permiten diferenciar claramente entre los perfiles solventes y aquellos que suponen un riesgo financiero para la entidad.

Aquí vemos una tabla para ver la relación de del target con el resto de variables utilizamos la función mutual_info_classif

	Variable	Mutual_Information_Score
0	cibil_score	0.507958
1	loan_term	0.022652
2	commercial_assets_value	0.012054
3	luxury_assets_value	0.005376
4	loan_amount	0.000912
5	self_employed	0.000733
6	loan_id	0.000322
7	no_of_dependents	0.000000
8	education	0.000000
9	income_annum	0.000000
10	residential_assets_value	0.000000
11	bank_asset_value	0.000000

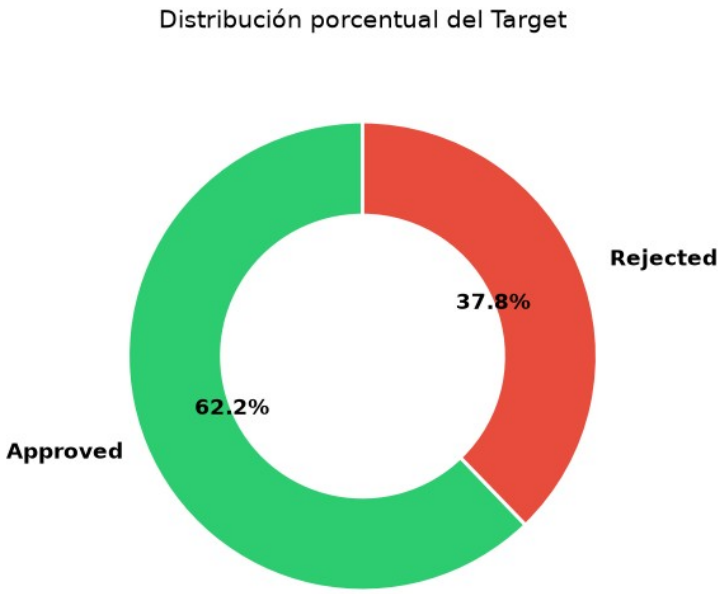
Como podemos ver en esta tabla `la puntuación cibil esta` como predictor principal la tabla refleja con total claridad que la puntuación de crédito (`cibil_score`) es, con diferencia, la variable más relevante del dataset, alcanzando un valor de **0.508**. Esto confirma de nuevo que el historial crediticio es el factor determinante para predecir el riesgo de impago.

Variables secundarias de apoyo, le siguen, con una influencia mucho menor pero existente, el plazo del préstamo (loan_term, 0.023) y el valor de los activos comerciales (commercial_assets_value, 0.012) y de lujo (luxury_assets_value, 0.005).

Variables con aporte residual o nulo, variables como el importe del préstamo (loan_amount), la condición de trabajador autónomo (self_employed) o el identificador (loan_id) muestran un valor prácticamente nulo. Por su parte, aspectos como el número de dependientes, nivel educativo, ingresos anuales o activos residenciales y bancarios registran una puntuación de 0.000, lo que indica que, de forma aislada, no aportan información compartida directa con la decisión final del crédito dentro de este conjunto de datos.

Distribución porcentual de la variable objetivo (*Target*):

- *Qué muestra el gráfico:* El diagrama de anular refleja cómo se divide el conjunto de datos entre las solicitudes de préstamos aprobadas (*Approved*, 62.2%) y las rechazadas o denegadas (*Rejected*, 37.8%).
- *Observación metodológica:* Este porcentaje demuestra que, aunque la clase mayoritaria corresponde a los créditos aprobados, existe una representación muy equilibrada y significativa de casos rechazados (cerca del 40%). Esto garantiza que el sistema cuenta con suficientes ejemplos de ambas clases para aprender a distinguirlas correctamente, evitando el problema del desbalanceo extremo que solemos encontrar en este tipo de datasets financieros.



5- Selección de modelo y justificación.

Para encontrar la mejor manera de predecir el riesgo de crédito, no limitamos el estudio a un único enfoque. Decidimos poner a prueba y comparar cuatro modelos diferentes de aprendizaje automático para comprobar cuál de ellos ofrecía el rendimiento más sólido, fiable y adaptado a la realidad financiera de los datos.

A continuación, se describen los cuatro algoritmos evaluados y el motivo por el cual se seleccionó el modelo definitivo:

1. Regresión Logística (*Logistic Regression*):
    - *Qué es:* Es un modelo estadístico clásico y directo que traza una línea divisoria matemática para separar los perfiles solventes de los de riesgo.
    - *Papel en el proyecto:* Al ser muy simple, permite comprobar un resultado rápido, pero se queda corto a la hora de entender relaciones complejas o curvas en los datos financieros.
2. Árbol de Decisión (*Decision Tree*):
    - *Qué es:* Un sistema en forma de esquema o diagrama de flujo que toma decisiones haciendo preguntas encadenadas (por ejemplo: *¿Tiene el cliente un historial de crédito superior a 700? Sí / No*).
    - *Papel en el proyecto:* Es extremadamente fácil de leer y entender, pero tiene el inconveniente de que tiende a "aprenderse los datos de memoria" (*overfitting*), fallando a menudo cuando se enfrenta a clientes nuevos que no había visto antes.
3. K-Vecinos Más Cercanos (*KNN*):
    - *Qué es:* Un algoritmo basado en la similitud; para decidir si un nuevo solicitante es un riesgo, busca en los datos históricos a los clientes que más se le parecen (sus "vecinos") y adopta la decisión mayoritaria de ese grupo.
    - *Papel en el proyecto:* Es un enfoque intuitivo, pero resulta lento cuando manejamos muchos datos y es muy sensible a variables que no aportan información real, lo que puede despistar sus conclusiones.

4. Bosques Aleatorios (*Random Forest* - Modelo Seleccionado):
    - *Qué es:* Una evolución inteligente del árbol de decisión que, en lugar de crear uno solo, genera decenas de pequeños árboles independientes que analizan el problema desde puntos de vista distintos. Al final, todos votan y gana la opción más respaldada.
    - *Por qué se selecciona como modelo principal:*
        - Trabajo en equipo: Al combinar muchas opiniones, evita los errores y la rigidez de un árbol individual.
        - Manejo de la complejidad: Entiende a la perfección las combinaciones lógicas del mundo real (cómo interactúan los ingresos, el plazo y el historial de crédito).
        - Estabilidad y seguridad: Es muy resistente al sobreajuste y ofrece una gran precisión, siendo el estándar de oro en muchos problemas de clasificación tabular en banca. Además, permite aplicar herramientas de explicabilidad como SHAP para auditar sus decisiones con total transparencia.

Resultados del Análisis de Validación Cruzada:

Para comparar de forma objetiva y sin sesgos el rendimiento de los cuatro algoritmos, se evaluó su desempeño mediante métricas de validación cruzada.

Estos son los resultados:

	model	accuracy_cv_mean	f1_cv_mean	roc_auc_cv_mean
2	Random Forest	0.971596	0.962264	0.994438
1	Decision Tree	0.961933	0.948759	0.992861
3	KNN	0.930600	0.908364	0.980262
0	Logistic Regression	0.910981	0.881706	0.964600

Random Forest se sitúa como el ganador indiscutible:

- Consigue la mayor precisión global (**accuracy de 97.16%**), acertando casi la totalidad de las predicciones.
- Su valor de **f1-score (96.23%)** demuestra un equilibrio perfecto entre la detección de impagos y la aprobación de clientes solventes.
- Su métrica **roc_auc (0.9944)** es prácticamente impecable, lo que confirma su enorme capacidad para distinguir entre perfiles de riesgo y no riesgo sin apenas cometer errores.

Comportamiento del resto de modelos:

- **Decision Tree (Árbol de Decisión):** Queda en segundo lugar con muy buenos resultados (**96.19% de exactitud y 0.9928 de roc_auc**), aunque ligeramente inferior a *Random Forest.*

- **KNN (K-Vecinos Más Cercanos):** Mantiene una exactitud sólida del **93.06%**, pero muestra una bajada en su equilibrio general (**f1-score de 90.84%**) en comparación con los modelos basados en árboles.

- **Logistic Regression (Regresión Logística):** Registra los valores más bajos del grupo (**91.10% de exactitud y f1-score de 88.17%**), evidenciando que una fórmula matemática lineal simple no logra capturar con la misma eficacia las relaciones complejas de los datos financieros.

Conclusión: La validación cruzada respalda la decisión de utilizar **Random Forest** como el modelo definitivo del proyecto, al ofrecer la mayor fiabilidad y robustez en todas las métricas evaluadas.Aun así vamos a comparar los cuatro modelos con el classification report y la matriz de confusión.

Vamos primero viendo los classification report y la matriz de confusión de cada modelo de manera independiente.

Comenzamos por Logistic regresion:

```
==========================================================
Logistic Regresion
==========================================================
Classification report
              precision    recall  f1-score   support

           0     0.9207    0.9623    0.9411       531
           1     0.9331    0.8638    0.8971       323

    accuracy                         0.9251       854
   macro avg     0.9269    0.9131    0.9191       854
weighted avg     0.9254    0.9251    0.9244       854

Matriz de confusion
[[511  20]
 [ 44 279]]
```

Acierto global (*Accuracy*): El modelo logra un acierto general del **92.51%**, lo que significa que clasifica correctamente a la gran mayoría de las personas que piden un préstamo.

Análisis de la Matriz de Confusión (Desglose de aciertos y fallos):

- **Casos aprobados/solventes (Clase 0):** De las 531 personas pagadoras, acertó 511 y solo se equivocó en 20 (falsos positivos). Muestra una gran capacidad para detectar a los clientes buenos (un 96.23% de sensibilidad o *recall*).
- **Casos de riesgo/impago (Clase 1):** De las 323 personas con riesgo real de impago, detectó correctamente a 279, pero se le escaparon **44 casos** (falsos negativos).

Conclusión práctica para el banco: Aunque es un modelo rápido y con buen porcentaje general, su principal debilidad en este contexto es que deja pasar 44 solicitudes de alto riesgo etiquetándolas como "buenas". En el sector bancario, estos fallos (prestar dinero a quien no va a devolverlo) suponen el riesgo económico más alto, por lo que este modelo actúa como una buena base pero deja margen de mejora para los siguientes algoritmos.

Continuamos por Decision tree:

```
============================================================
Decision Tree
============================================================
Classification report
              precision    recall  f1-score   support

           0     0.9511    0.9887    0.9695       531
           1     0.9801    0.9164    0.9472       323

    accuracy                         0.9614       854
   macro avg     0.9656    0.9526    0.9584       854
weighted avg     0.9621    0.9614    0.9611       854

Matriz de confusion
[[525   6]
 [ 27 296]]
```

Acierto global (*Accuracy*): El modelo alcanza una exactitud del **96.14%**, superando de forma clara el 92.51% que conseguía la Regresión Logística.

Análisis de la Matriz de Confusión (Desglose de aciertos y fallos):

- **Casos aprobados/solventes (Clase 0):** De las 531 personas pagadoras, el árbol clasifica correctamente a **525** y solo se equivoca rechazando a **6** (falsos positivos). Logra una sensibilidad (*recall*) excelente del **98.87%**.
- **Casos de riesgo/impago (Clase 1):** De los 323 clientes con riesgo de impago, detecta correctamente a **296** y deja pasar únicamente a **27** (falsos negativos), alcanzando un *recall* del **91.64%** y una precisión del **98.01%**.

Conclusión práctica para el banco:

El Árbol de Decisión supone un salto de calidad muy importante. Al ser capaz de entender reglas y condiciones cruzadas en los datos, reduce drásticamente el peligro económico para la entidad, disminuyendo los casos de impago no detectados de 44 (en la Regresión Logística) a solo **27**.

Seguimos por Random forest:

```
============================================================
Random Forest
============================================================
Classification report
              precision    recall  f1-score   support

           0     0.9704    0.9868    0.9785       531
           1     0.9777    0.9505    0.9639       323

    accuracy                         0.9731       854
   macro avg     0.9740    0.9686    0.9712       854
weighted avg     0.9731    0.9731    0.9730       854

Matriz de confusion
[[524   7]
 [ 16 307]]
```

Acierto global (*Accuracy*): El modelo alcanza la exactitud más alta de todo el estudio con un **97.31%**, superando tanto a la Regresión Logística (92.51%) como al Árbol de Decisión individual (96.14%).

Análisis de la Matriz de Confusión (Desglose de aciertos y fallos):

- **Casos aprobados/solventes (Clase 0):** De las 531 personas pagadoras, el sistema clasifica correctamente a **524** y solo se equivoca rechazando a **7** (falsos positivos), obteniendo un nivel de acierto (*recall*) excepcional del **98.68%**.
- **Casos de riesgo/impago (Clase 1):** De los 323 clientes con riesgo real de impago, el modelo detecta de forma impecable a **307** y deja pasar únicamente a **16** (falsos negativos). Esto representa un *recall* del **95.05%** y una precisión del **97.77%**.

Conclusión práctica para el banco:

Este es el gran valor diferencial del modelo seleccionado. Frente a los 44 fallos de la Regresión Logística y los 27 del Árbol de Decisión, *Random Forest* reduce los impagos colados a solo **16 casos**. Gracias a la combinación de múltiples árboles trabajando en equipo, el sistema consigue el equilibrio perfecto: protege al máximo a la entidad financiera contra el riesgo de impago sin perjudicar injustamente a los clientes solventes.

Finalmente vemos KNN:

```
============================================================
KNN
============================================================
Classification report
              precision    recall  f1-score   support

           0     0.9320    0.9548    0.9433       531
           1     0.9226    0.8854    0.9036       323

    accuracy                         0.9286       854
   macro avg     0.9273    0.9201    0.9234       854
weighted avg     0.9284    0.9286    0.9283       854

Matriz de confusion
[[507  24]
 [ 37 286]]
```

Acierto global (*Accuracy*): El modelo alcanza una exactitud del **92.86%**, situándose muy a la par de la Regresión Logística (92.51%) pero por debajo de los modelos basados en árboles (Árbol de Decisión y Random Forest).

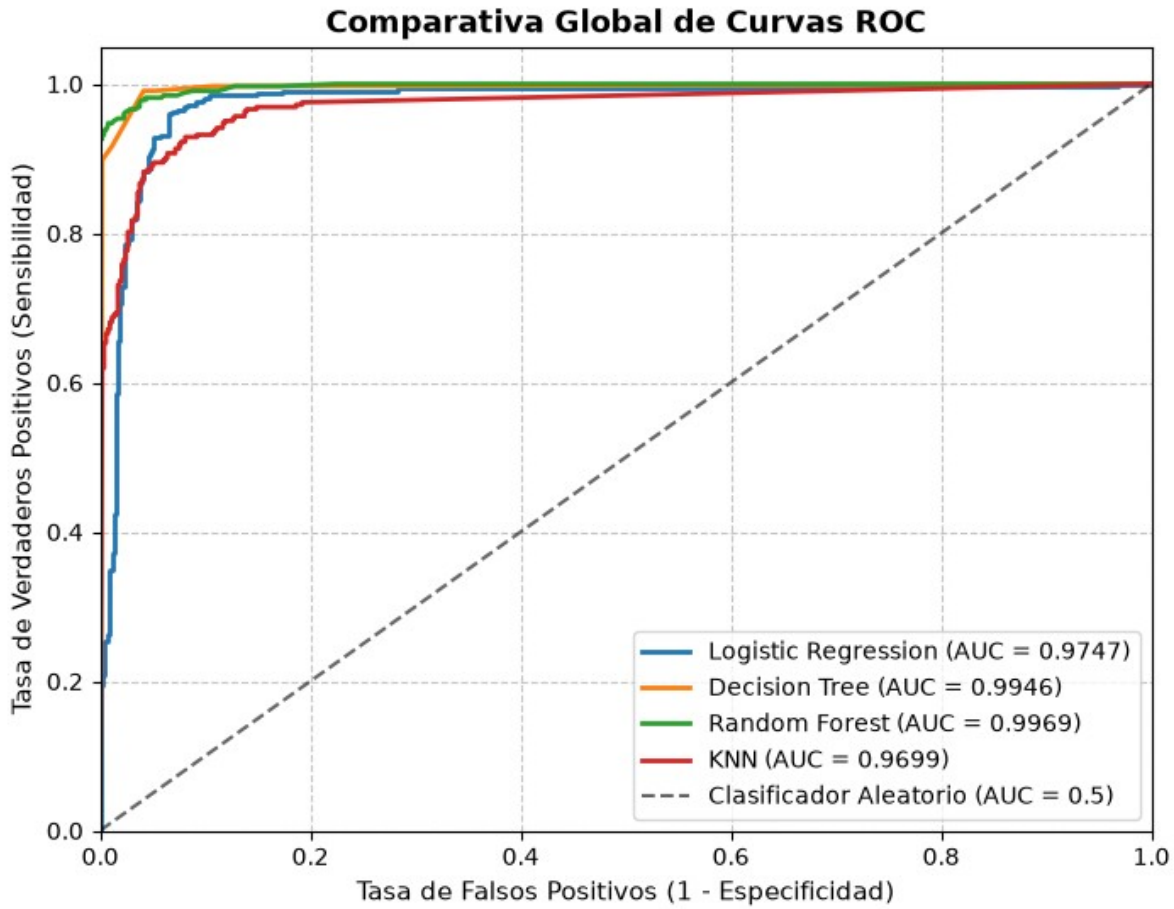
Análisis de la Matriz de Confusión (Desglose de aciertos y fallos):

- **Casos aprobados/solventes (Clase 0):** De los 531 clientes pagadores, el modelo clasifica correctamente a **507** y se equivoca rechazando a **24** (falsos positivos), logrando un *recall* del **95.48%**.
- **Casos de riesgo/impago (Clase 1):** De los 323 clientes con riesgo de impago, detecta correctamente a **286** pero deja pasar a **37** (falsos negativos), obteniendo un *recall* del **88.54%**.

Conclusión práctica para el banco:

Aunque KNN ofrece un comportamiento aceptable y supera ligeramente a la Regresión Logística en precisión global, se queda rezagado frente a *Random Forest*.Al depender exclusivamente de buscar vecinos cercanos en los datos, le cuesta más capturar las reglas financieras complejas y comete más errores dejando pasar a clientes de riesgo (37 casos no detectados), lo que refrenda aún más la idoneidad de haber escogido *Random Forest* como la opción principal del proyecto.

Ahora vamos a comparar los cuatro modelos en la curva ROC:



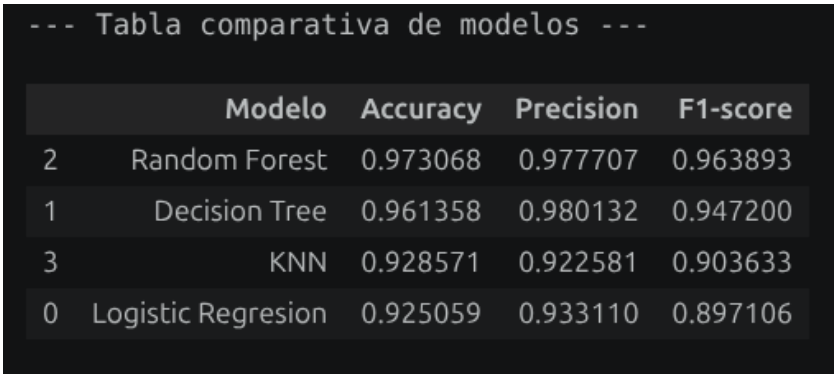
Comparativa Global de Curvas ROC:

El gráfico muestra las curvas ROC (*Receiver Operating Characteristic*) de los cuatro algoritmos evaluados. Esta representación gráfica evalúa la capacidad de cada modelo para distinguir entre los clientes solventes y aquellos con riesgo de impago, midiendo el equilibrio entre los aciertos (*tasa de verdaderos positivos*) y los errores (*tasa de falsos positivos*). Cuanto más se pegue la línea hacia la esquina superior izquierda, mejor será el modelo (representado por el valor del **AUC** o Área Bajo la Curva, donde el máximo ideal es 1.0):

El análisis gráfico de las curvas ROC corrobora de forma concluyente los resultados de las matrices de confusión: los algoritmos basados en árboles superan con claridad a los modelos lineales y de vecinos, siendo **Random Forest** la opción más potente y fiable para proteger a la entidad financiera.

Tabla Comparativa Global de Modelos

Esta tabla reúne los resultados de las tres métricas clave (**Exactitud, Precisión y F1-score**) para evaluar a todos los modelos en el conjunto de prueba:



--- Tabla comparativa de modelos ---

	Modelo	Accuracy	Precision	F1-score
2	Random Forest	0.973068	0.977707	0.963893
1	Decision Tree	0.961358	0.980132	0.947200
3	KNN	0.928571	0.922581	0.903633
0	Logistic Regresion	0.925059	0.933110	0.897106

1. Random Forest (Líder Absoluto):

- Es el claro ganador del estudio con un **97.31% de acierto global** y un **F1-score de 0.9639**.
- Demuestra el mejor equilibrio entre detectar impagos y no equivocarse con los clientes solventes, ofreciendo la máxima estabilidad general.

2. Decision Tree / Árbol de Decisión:

- Ocupa el segundo lugar con un **96.14% de acierto** y un **F1-score de 0.9472**.
- Aunque es un modelo muy acertado, se queda un paso por detrás de *Random Forest* al depender de un único árbol en lugar del trabajo en equipo.

3. KNN (K-Vecinos Más Cercanos):

- Alcanza un **92.86% de acierto** y un **F1-score de 0.9036**.
- Ofrece un rendimiento correcto, pero se queda rezagado al limitarse a comparar perfiles similares.

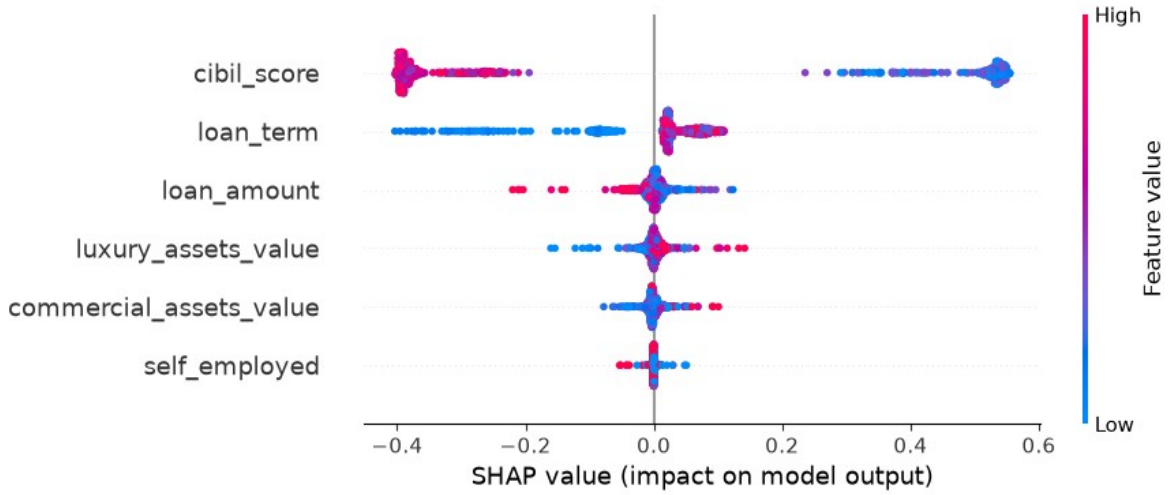
4. Logistic Regression / Regresión Logística:

- Cierra la tabla con las puntuaciones más bajas (**92.51% de acierto** y **0.8971 de F1-score**).
- Confirma que una fórmula matemática simple resulta insuficiente para capturar el riesgo financiero real.

Conclusión: Los datos confirman de forma clara que **Random Forest** es la mejor opción para este proyecto.

6- Representación final de los resultados con la librería SHAP.

Este gráfico nos permite "abrir la caja negra" de nuestro modelo *Random Forest* para entender exactamente qué factores prioriza a la hora de aprobar o rechazar un préstamo:



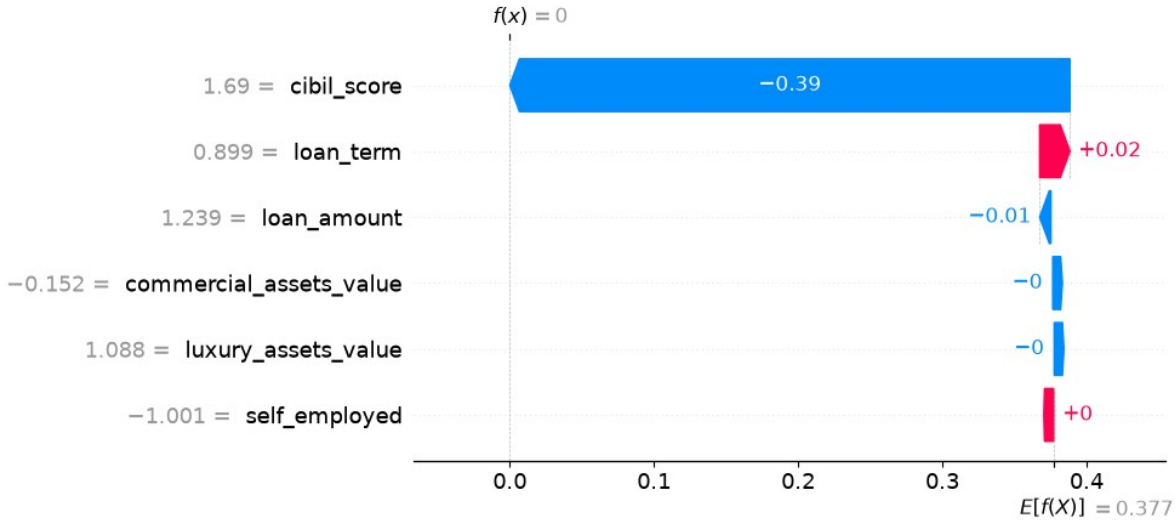
El rey indiscutible (`cibil_score`):

- Ocupa la primera posición con diferencia. Los puntos azules (valores bajos de puntuación de crédito) se concentran fuertemente hacia la izquierda, lo que significa que un mal historial empuja de forma drástica la decisión hacia el rechazo. Por el contrario, los puntos rosas (valores altos) se extienden hacia la derecha, impulsando la aprobación. Esto confirma que el historial crediticio es el factor de peso absoluto para el modelo.

Factores secundarios de apoyo (`loan_term`, `loan_amount`, etc.):

- Variables como el plazo del préstamo (`loan_term`) o la cantidad solicitada (`loan_amount`) también aportan matices en la decisión, pero su impacto está mucho más concentrado cerca del centro. Esto indica que influyen en casos concretos, pero tienen un peso muy inferior en comparación con el historial de crédito.
- Los activos (comerciales y de lujo) y la situación laboral (`self_employed`) muestran un impacto casi neutro o muy reducido, alineándose con lo que ya vaticinaba el análisis inicial de los datos.

Vemos también un ejemplo con el primer cliente para demostrar todo lo visto asta ahora:



Conclusión:

El análisis SHAP demuestra que el modelo toma decisiones de manera totalmente lógica y coherente con el sentido común bancario, basando sus veredictos principalmente en la solvencia y el historial del solicitante.